probability
probability

第九章

回 归 分 析

probability
probability

§9.1 相关关系与回归分析

§9.2 一元回归分析

§9.1 相关关系与回归分析

一. 相关关系与回归函数

在现实世界中存在大量的变量,它们有相互依存、相互制约的关系，一般分为两类：确定性关系与非确定性关系.

Ex.1 球的直径 X 与球的体积 V 之间有确定的函数关系

$$V=\frac{1}{6}\pi X^3$$

Ex.2 随机信号

$$X(t)=A\cos(\omega t+\Theta),\quad t\in R,$$

由振幅 $A\sim N(\mu,\sigma^2)$ 和初相角 $\Theta\sim U(-\pi,\pi)$ 确定.

还有另一类变量关系，如：

Ex.3（救救长江）江河上游地区森林覆盖面积Y与下游的水流量X之间的关系.

Ex.4 农作物产量Y与降雨量X_1，氮、磷、钾的施肥量X_2、X_3、X_4之间的关系.

EX. 5 产品的价格X与需求量M之间存在关系.

特点 变量间的关系无法用确定的函数来明确表述.

问题 如何描述变量间的各类关系?

将作为考察目标的变量称为因变量(记为Y), 而将影响它的各个变量称为自变量或可控变量, 记为

$$(X_1, X_2, \cdots X_k)$$

1.确定性的函数关系

用第三章方法可求随机变量函数的分布.

若已知随机变量X的分布就可以确定函数

$$V=\frac{1}{6}\pi X^3$$

的分布.

由振幅和初相角的分布可以完全确定随机信号

$$X(t)=A\cos(\omega t+\Theta),\ t\in R,$$

的分布.

2.非确定性的相关关系

EX. 6 已测得SCS系统的输入和输出信号，如何确定输入和输出之间的关系？（P230非线性交调的频率设计）



设想 构造某种函数来描述输入和输出之间的非确定关系.

随机变量的相关关系引进：

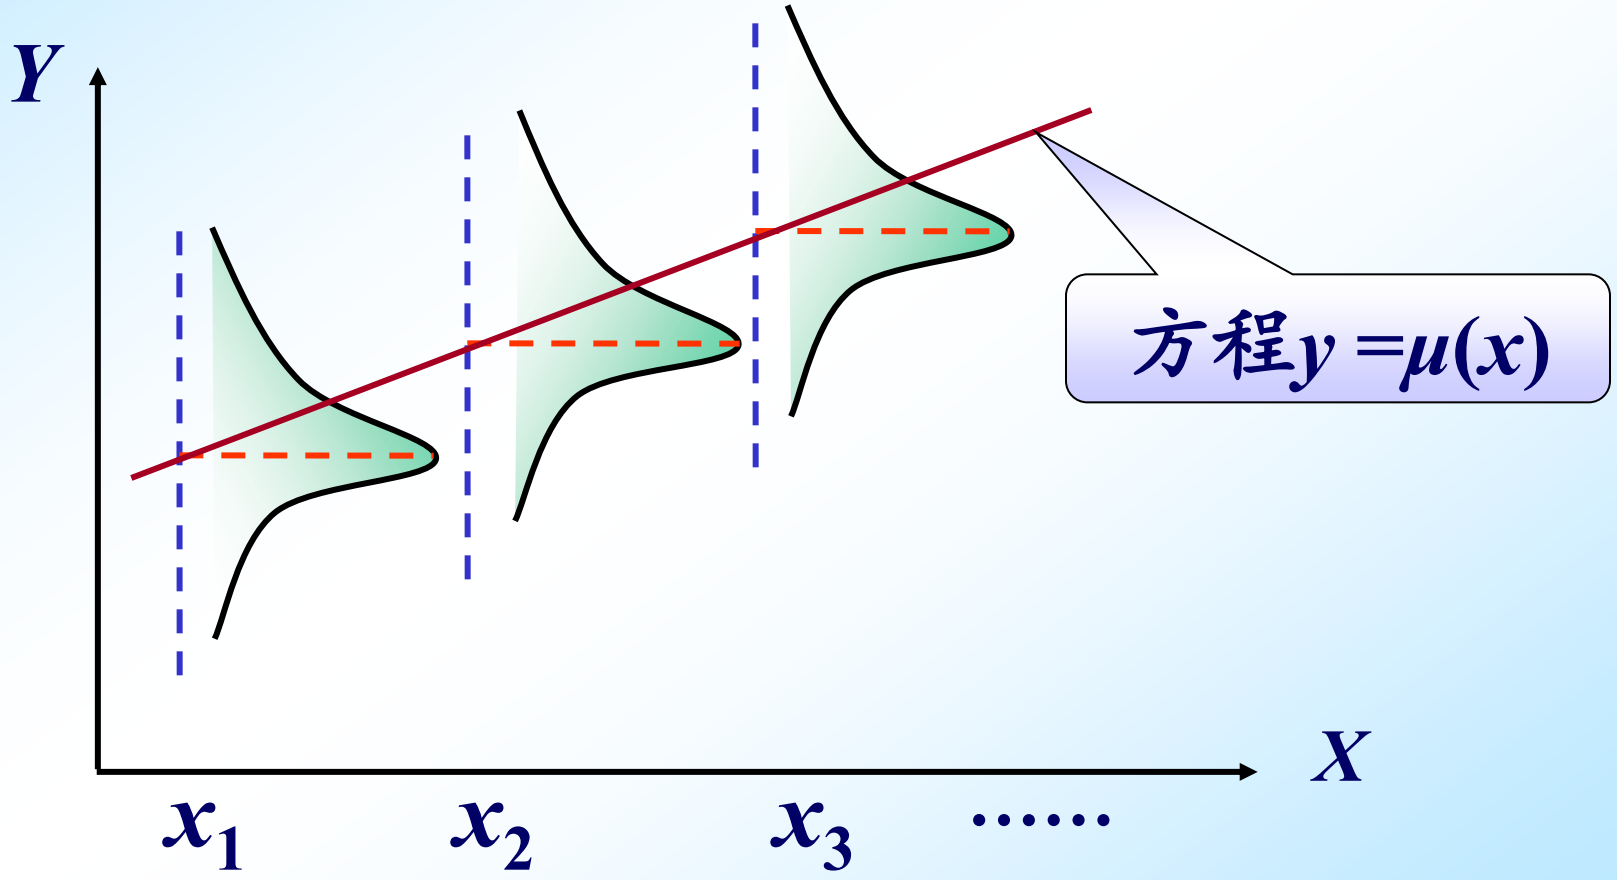
考虑单个因变量Y与单个自变量X的情形.

在“$X=x$”时，Y(连续型)的条件数学期望为

$$\mu(x)=E(Y|X=x)=\int_{-\infty}^{+\infty}yf_{Y|X}(y|x)dy$$

1) $\mu(x)$可理解为在“$X=x$”的条件下，随机变量Y取值的集中点；

对于X的不同取值x_1, x_2, …, x_n



2）方程 $y=\mu(x)$ 描述了 Y 与 X 间非确定性的关系.

将可控变量 X_1，X_2，$\cdots$ X_k 的取值记为 x_1，x_2,…, x_k, 若条件数学期望：

$$\mu(x_1,x_2,\cdots,x_k)=E(Y|X_1=x_1,X_2=x_2,\cdots X_k=x_k)$$

存在，称 Y 与 X_1，X_2，$\cdots$ X_k 具有**相关关系**.

相关关系是一种**非确定性关系**

定义9.1.1 称

$$\mu(x_1,x_2,\cdots,x_k)=E(Y|X_1=x_1,X_2=x_2,\cdots X_k=x_k)$$

为Y关于X_1，X_2，$\cdots$ X_k的**回归函数**，方程

$$y=\mu(x_1,x_2,\cdots,x_k)$$

称为Y对X_1，X_2，$\cdots$ X_k的**回归方程**.

注 回归函数是确定性的函数.

回归分析是从回归函数出发处理相关关系的方法.

“回归”一词的由来

高尔顿，生物统计学派的奠基人，他的表哥达尔文的巨著《物种起源》问世以后，触动他用统计方法研究智力遗传进化问题，第一次将概率统计原理等数学方法用于生物科学，明确提出“生物统计学”的名词.

统计学上的“相关”和“回归”的概念是由高尔顿首先引进。

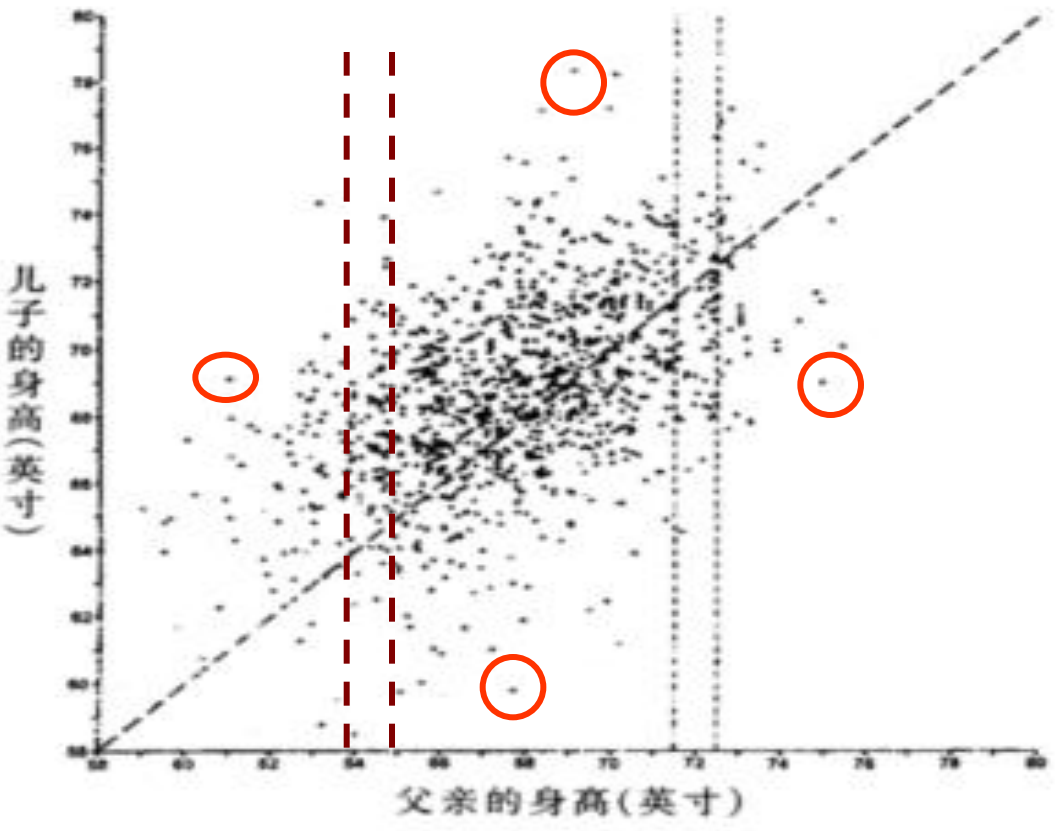


图1 1078对父子身高的散点图

高尔顿的学生卡尔·皮尔逊（Karl Pearson）测量了1078个父亲及其成年儿子的身高.

1870年，高尔顿在研究人类身长的遗传问题时，发现下列规律：

1. 高个子的父亲有着较高身材的儿子，而矮个子父亲的儿子身材也比较矮；

2. 高个子父母的子女，其身高有低于其父母身高的趋势；

3. 而矮个子父母的子女，其身高有高于其父母的趋势；

即有“回归”到平均值的趋势，这就是统计学上最初出现“回归”时的涵义.

3.回归模型的引进

若Y关于X_1，X_2，$\cdots$ X_k的回归函数为

$$y=\mu(x_1,x_2,\cdots,x_k)$$

设想：$Y=\mu(x_1,x_2,\cdots,x_k)+$ 随机误差

得数学模型：

$$Y=\mu(x_1,x_2,\cdots,x_k)+\varepsilon$$

$$\varepsilon=Y-\mu(x_1,x_2,\cdots,x_k)$$

可视为随机误差，通常要求：

其它未知的、未考虑的因素以及随机因素的影响所产生.

1) $E(\varepsilon)=0$;

2) $D(\varepsilon)=E(\varepsilon^2)=\sigma^2$ 尽可能小.

注意到 $\sigma^2 = E[Y-\mu(x_1,x_2,\cdots,x_n)]^2$

σ^2 是用回归函数近似因变量Y产生的均方误差.

建立模型涉及三个问题:

1) 确定对因变量Y影响显著的自变量;

2) 确定回归函数$\mu(x)$的类型;

3) 对参数进行估计.

} 本章内容

二. 回归函数类型的估计确定

实际问题中，通常未知回归函数形式.

回归分析的**基本思想**：

根据自变量X_1，X_2，$\cdots$ X_k与因变量Y的观察值去**估计**回归函数.

本节仅讨论最简单的情形：可控变量Y关于单个因变量X的回归函数存在

$$\mu(x) = E(Y|X = x).$$

问题的提法 对两个变量X、Y间的回归函数$y=\mu(x)$，选择某个函数$S(x)$作为其估计函数：

$$\hat{\mu}(x)=S(x)$$

为估计回归函数，可依据问题的背景，确定或假定回归函数的形式.称

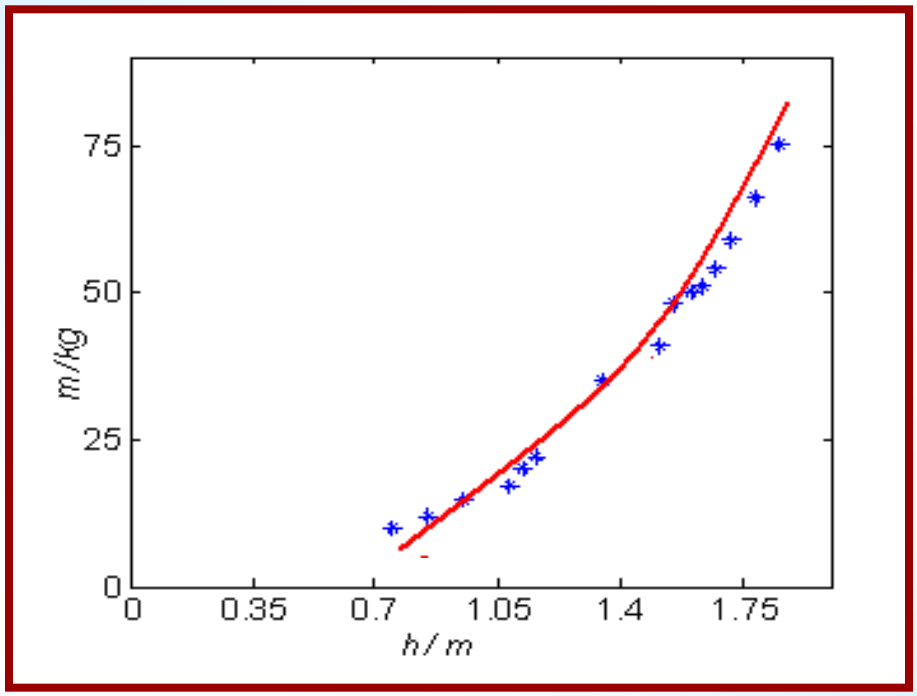
$$y=\hat{\mu}(x)=S(x)$$

为Y关于X的经验回归方程.

常通过分析数据散布图获得对变量间相关关系的初步认识.

例9.1.1 身高体重关系

希望根据某地区人的15对身高h和体重数据m，用简洁的函数关系式描述该地区人的身高体重的对应关系.



呈现幂函数的增长趋势，可设

$$m = \hat{\mu}(h) = dh^a$$

其中a, d是待定参数.

例9.1.2 施肥效果分析

某地区作物生长所需的营养素主要是氮(*N*)、钾(*K*)、磷(*P*).某作物研究所在某地区对土豆做了一定数量的实验,实验数据如下列表所示,其中*ha*表示公顷,试分析施肥量与土豆产量之间关系.

N

施肥量 (kg/ha)	产量 (t/ha)
0	15.18
34	21.36
67	25.72
101	32.29
135	34.03
202	39.45
259	43.15
336	43.46
404	40.83
471	30.75

P

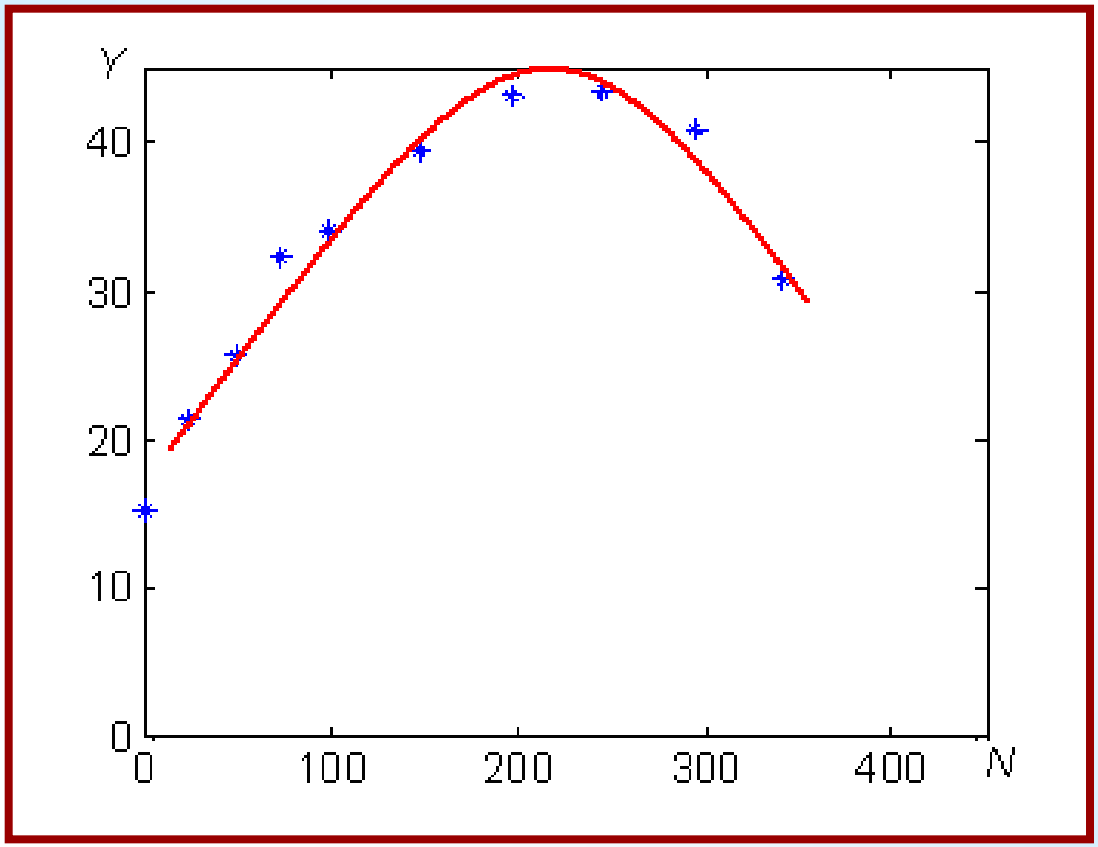
施肥量 (kg/ha)	产量 (t/ha)
0	34.46
24	32.47
49	36.06
73	37.96
98	41.04
147	40.09
196	41.26
245	42.17
294	40.36
342	42.73

K

施肥量 (kg/ha)	产量 (t/ha)
0	18.98
47	27.35
93	34.86
140	39.92
186	38.44
279	37.73
372	38.43
465	43.87
558	42.77
651	46.22

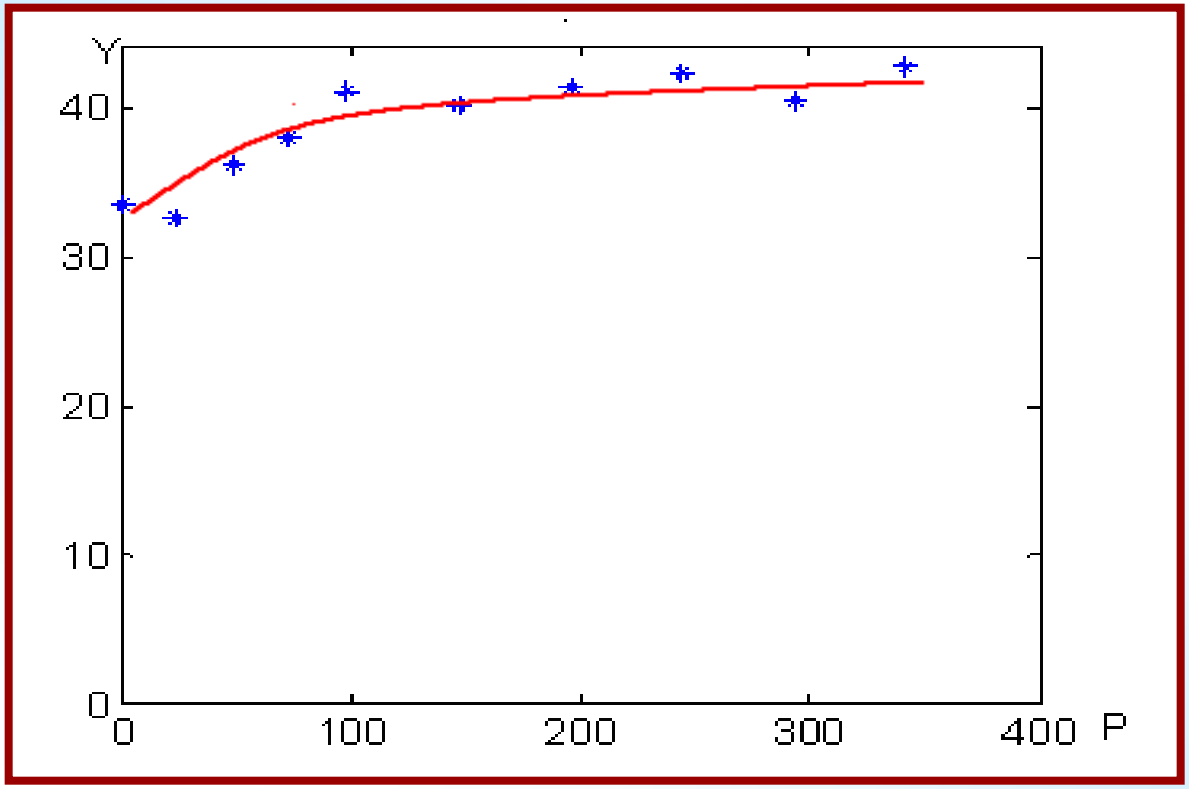


土豆产量—氮肥量数据散布图



可令 $y = \hat{\mu}(x) = b_0 + b_1 x + b_2 x^2$

土豆产量—磷肥量数据散布图



可选 $y = \hat{\mu}(x) = \dfrac{1}{a + be^{-x}}, x \geq 0$

问题 观察法的依据?

因回归函数$\mu(x)$是在“$X=x$”的条件下Y的数学期望，随机变量Y取值的集中点.

根据小概率实际推断原理，做一次试验得到的数据最可能密集在其回归曲线及其附近.

思考 是否能由数据散布图完全确定回归函数的类型和形式?

结论 仅是初步感性的认识，需进行检验.